

車輛規格資料集

3B341016

魏平凡

目錄

- 問題定義
- 數據收集
- 數據前處理
- 探索性數據分析
- 特徵工程
- 機器學習模型建構
- 模型評估

問題定義

能否根據一輛汽車的技術規格與歷史狀況，準確預測其市場價格？

2026 年最可靠的汽車品牌



數據收集

本專案所使用的資料集來自 Kaggle 平台，由使用者Upcoderr 發布的 Car Specifications Dataset。該資料集為合成資料，但設計上貼近真實車輛市場的規格與價格分布。

資料取得方式：

下載連結：<https://www.kaggle.com/datasets/upcoderr/car-specifications-dataset/data>

檔案名稱：car_price_dataset.csv

檔案大小：約 119 KB

資料初步概覽：

總筆數：2000筆

總欄位數：11 欄

目標變數：Price (價格，單位 USD)

特徵變數：Brand, Model_Year, Engine_Size, Fuel_Type, Transmission, Mileage, Doors, Owner_Count, Horsepower

數據收集

汽車編號	品牌	出廠年份 (年)	引擎排氣 量(L)	燃料類型	變速箱	里程 (km)	車門數 (個)	前任車主數 (人)	馬力 (HP)	價格 (USD)
0	Ford	2023	1.2	Hybrid	手動	180635	4	3	82	34309.25
1	Hyundai	2018	3.2	Electric	手動	35628	2	4	259	55153.60
2	BMW	2008	2.2	Diesel	手動	74672	3	2	333	41894.40
3	Hyundai	2017	2.2	Petrol	自動	51246	4	4	381	54046.70
4	Hyundai	2012	2.4	Electric	手動	147233	3	4	290	38010.35

(2000, 11)

	Car_ID	Brand	Model_Year	Engine_Size	Fuel_Type	Transmission	Mileage	\	Doors	Owner_Count	Horsepower	Price
0	1	Ford	2023	1.2	Hybrid	Manual	180635	0	4	3	82	34309.25
1	2	Hyundai	2018	3.2	Electric	Manual	35628	1	2	4	259	55153.60
2	3	BMW	2008	2.2	Diesel	Manual	74672	2	3	2	333	41894.40
3	4	Hyundai	2017	2.2	Petrol	Automatic	51246	3	4	4	381	54046.70
4	5	Hyundai	2012	2.4	Electric	Manual	147233	4	3	4	290	38010.35

數據收集

#	欄位名稱	非空值數量	資料型態
0	汽車編號	2000	int64
1	品牌	2000	object
2	出廠年份(年)	2000	int64
3	引擎排氣量(L)	2000	float64
4	燃料類型	2000	object
5	變速箱	2000	object
6	里程(km)	2000	int64
7	車門數(個)	2000	int64
8	前任車主數(人)	2000	int64
9	馬力(HP)	2000	int64
10	價格(USD)	2000	float64

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2000 entries, 0 to 1999
Data columns (total 11 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Car_ID          2000 non-null   int64
1   Brand           2000 non-null   object
2   Model_Year      2000 non-null   int64
3   Engine_Size     2000 non-null   float64
4   Fuel_Type       2000 non-null   object
5   Transmission    2000 non-null   object
6   Mileage         2000 non-null   int64
7   Doors           2000 non-null   int64
8   Owner_Count     2000 non-null   int64
9   Horsepower      2000 non-null   int64
10  Price           2000 non-null   float64
dtypes: float64(2), int64(6), object(3)
memory usage: 172.0+ KB
None
```

數據前處理

欄位名稱	缺失值數量
汽車編號	0
品牌	0
出廠年份(年)	0
引擎排氣量(L)	0
燃料類型	0
變速箱	0
里程(km)	0
車門數(個)	0
前任車主數(人)	0
馬力(HP)	0
價格(USD)	0

```
(2000, 11)
  Car_ID      Brand  Model_Year  Engine_Size  Fuel_Type  Transmission  Mileage  \
0         1      Ford        2023          1.2    Hybrid          Manual    180635
1         2  Hyundai        2018          3.2    Electric          Manual     35628
2         3       BMW        2008          2.2     Diesel          Manual     74672
3         4  Hyundai        2017          2.2     Petrol    Automatic     51246
4         5  Hyundai        2012          2.4    Electric          Manual    147233

  Doors  Owner_Count  Horsepower    Price
0      4             3          82  34309.25
1      2             4         259  55153.60
2      3             2         333  41894.40
3      4             4         381  54046.70
4      3             4         290  38010.35

Car_ID      0
Brand        0
Model_Year   0
Engine_Size  0
Fuel_Type    0
Transmission 0
Mileage      0
Doors        0
Owner_Count  0
Horsepower   0
Price        0
dtype: int64
```

所有欄位的缺失值數量皆為 0，資料集無缺失值。

數據前處理

欄位名稱	資料型態	檢查項目	異常值數量
汽車編號	int64	里程負數	0
品牌	object		
出廠年份(年)	int64	價格小於等於0	0
引擎排氣量(L)	float64	馬力小於等於0	0
燃料類型	object		
變速箱	object	車門數小於2	0
里程(km)	int64		
車門數(個)	int64	車門數小於2	0
前任車主數(人)	int64		
馬力(HP)	int64		
價格(USD)	float64		

```
=== 資料型態 ===
Car_ID      int64
Brand       object
Model_Year  int64
Engine_Size float64
Fuel_Type   object
Transmission object
Mileage     int64
Doors       int64
Owner_Count int64
Horsepower  int64
Price       float64
dtype: object

=== 異常值檢查 ===
里程負數? 0
價格小於等於0? 0
馬力小於等於0? 0
車門數小於2? 0
```

各檢查項目異常值數量皆為0，資料集無明顯異常值。

數值欄位皆為整數或小数，類別欄位（品牌、燃料類型、變速箱）為文字型態，需後續編碼處理。

數據前處理


出廠年份 (年)	車齡 (年)	里程 (km)	年均里程 (km/年)
2023	3	180635	60211.67
2018	8	35628	4453.50
2008	18	74672	4148.44
2017	9	51246	5694.00
2012	14	147233	10516.64
項目		欄位數	
編碼前		13	
編碼後		19	

項目	形狀
特徵X	(2000,18)
目標y	(2000,)


新增的欄位：				
	Model_Year	Car_Age	Mileage	Mileage_per_Year
0	2023	3	180635	60211.666667
1	2018	8	35628	4453.500000
2	2008	18	74672	4148.444444
3	2017	9	51246	5694.000000
4	2012	14	147233	10516.642857
編碼前的欄位數：13				
編碼後的欄位數：19				
特徵 X 的形狀：(2000, 18)				
目標 y 的形狀：(2000,)				

新增「車齡」與「年均里程」兩個衍生特徵。經 One-Hot Encoding 編碼後，欄位數從 13 增加至 19。最終特徵 X 為 2000 筆 × 18 個欄位，目標 y 為 2000 筆價格資料。


探索性數據分析




價格分布直方圖



價格盒鬚圖



馬力 VS 價格
(散佈圖)



車齡 VS 價格
(散佈圖)


圖 1 價格分布集中在 20,000 至 40,000 美元之間。

圖 2 盒鬚圖顯示無明顯離群值。

圖 3 馬力與價格呈正相關，馬力越大價格越貴。


圖 4 車齡與價格呈負相關，車越老價格越低。

探索性數據分析




各品牌平均價格
(長條圖)

圖5 豪華品牌 (BMW) 價格高於一般品牌。




燃料類型 VS 價格
(盒鬚圖)

圖6 電動車與油電車價格高於汽油車。



相關性熱圖

圖7 與價格相關性最高的變數為馬力 (0.75)，車齡 (-0.68) 與里程 (-0.45) 則呈負相關。



變速箱 VS 價格
(盒鬚圖)

圖8 自動排檔價格高於手動排檔。

特徵工程

	引擎排氣量(L)	里程(km)	前任車主數(人)	馬力(HP)	車齡(年)	年均里程(公里/年)	標準化前-馬力統計 平均值: 235.71 標準差: 95.60
0	-1.541505	1.427033	0.415503	-1.608274	-1.641041	4.482088	標準化後-馬力統計: 平均值:0.00 標準差1.00
1	0.202723	-1.162890	1.304280	0.243690	-0.733084	-0.644437	
2	-0.669391	-0.465538	-0.473274	1.017958	1.082829	-0.672485	
3	-0.669391	-0.883942	1.304280	1.520185	-0.551493	-0.530383	
4	-0.494968	0.830451	1.304280	0.568046	0.356464	-0.086979	

標準化前 - 馬力統計:
平均值: 235.71
標準差: 95.60

標準化後 - 馬力統計:
平均值: 0.00
標準差: 1.00

標準化後的數值特徵（前5筆）：

	Engine_Size	Mileage	Owner_Count	Horsepower	Car_Age	Mileage_per_Year
0	-1.541505	1.427033	0.415503	-1.608274	-1.641041	4.482088
1	0.202723	-1.162890	1.304280	0.243690	-0.733084	-0.644437
2	-0.669391	-0.465538	-0.473274	1.017958	1.082829	-0.672485
3	-0.669391	-0.883942	1.304280	1.520185	-0.551493	-0.530383
4	-0.494968	0.830451	1.304280	0.568046	0.356464	-0.086979


標準化後，所有數值特徵的平均值為 0、標準差為 1

機器學習模型建構

模型	說明	原因	項目	比例	筆數
線性回歸	假設特徵與價格呈線性關係	簡單、可解釋性強，作為基準模型	訓練集	80%	1600筆
隨機森林	多棵決策樹的集成模型	可處理非線性關係，不易過擬合	測試集	20%	400筆
XGBoost	梯度提升樹模型	比賽常用，通常表現最佳	1.使用訓練集進行訓練(.fit) 2.使用測試集進行預測(.predict) 3.計算評估指標(MAE、RMSE、R²) MSE最低:平均誤差1442美元 RMSE最低:對大誤差懲罰最小 R²最高:能解釋96.6%的價格變異 ★選用 線性迴歸 作為最終預測模型		
	MAE(USD)	RMSE(USD)	R ²		
線性回歸	1442	1663	0.966		
隨機森林	2181	2696	0.912		
XGBoost	1879	2343	0.933		

模型評估


	MAE(USD)	RMSE(USD)	R ²
線性回歸	1442	1663	0.966
隨機森林	2181	2696	0.912
XGBoost	1879	2343	0.933



最佳模型：線性回歸

平均預測誤差：1442 USD

模型解釋力 R²：0.966





THANK YOU